

Triển khai, phát triển ứng dụng AI và IoT | Lab 4 v4 Upgrade

LAB 4 v4 UPGRADE

AI MODEL TRAINING FOR IoT FORECASTING & PREDICTIVE ANALYTICS

Từ dữ liệu cảm biến đến model dự báo, đánh giá sai số, tinh chỉnh tham số và khám phá LSTM

Thông tin	Nội dung
Học phần	Triển khai, phát triển ứng dụng AI và IoT
Vị trí	Buổi 4 trong chuỗi AIoT Intelligence & Deployment Pipeline
Trọng tâm bản v4	Hiểu và train model AI cho bài toán forecasting; API không phải trực chính
Dataset chính	UCI Appliances Energy Prediction - target Appliances
Dataset so sánh	UCI Occupancy Detection - dùng CO2 làm target forecasting
Model	Last Value, Moving Average, Linear/Ridge, Random Forest, Gradient Boosting, LSTM mở rộng
Sản phẩm	Notebook, source code, metrics, tuning_log.csv, predictions, figures, model card

Thông điệp mở đầu

Lab 4 v4 không dạy sinh viên gọi model cho có. Lab này yêu cầu sinh viên hiểu model học gì từ dữ liệu IoT, sai ở đâu, vì sao sai, và có đáng tin để đưa vào hệ thống AIoT hay không.

I. Định vị Lab 4 v4 trong lộ trình môn học

Ở Lab 2, sinh viên đã học cách làm dữ liệu sẵn sàng cho AI. Ở Lab 3, dữ liệu sạch được đưa vào event pipeline để phát hiện bất thường, sinh anomaly_score, severity và anomaly_event_log. Lab 4 v4 chuyển trọng tâm sang model AI cho forecasting: model nhận dữ liệu quá khứ và dự báo một giá trị trong tương lai gần.

Lab	Câu hỏi trung tâm	Vai trò của model	Output chính
Lab 1	Hệ thống AIoT cần giải quyết vấn đề gì?	Xác định AI module trong kiến trúc	Use-case, dữ liệu, feedback loop
Lab 2	Dữ liệu đã sẵn sàng cho AI chưa?	Baseline để kiểm tra data pipeline	Feature dataset, API /predict
Lab 3	Hệ thống có đang bất thường không?	Tạo anomaly_score để chuyển thành event	anomaly_event_log.csv, severity, API /detect-anomaly

Lab 4 v4	Model AI học từ dữ liệu IoT như thế nào?	Trọng tâm: train, test, evaluate, tune	metrics, predictions, tuning_log, model card
Lab 5	Đóng gói model thành service thế nào?	Model đã train được deploy	AI inference service nhiều endpoint

Câu hỏi dẫn nhập cho sinh viên

- Lab 3 trả lời câu hỏi đang bất thường hay không. Lab 4 trả lời câu hỏi nào?
- Nếu model chỉ dự báo một con số nhưng không đánh giá sai số, hệ thống có thể tin model không?
- Vì sao API nên để sau khi sinh viên hiểu cách train và test model?

II. Vì sao cần model AI trong AIoT forecasting?

Trong hệ thống IoT, nhiều quyết định vận hành không nên chỉ dựa vào trạng thái hiện tại. Ví dụ, CO2 trong phòng chưa vượt ngưỡng nhưng đang tăng nhanh; điện năng chưa quá tải nhưng xu hướng tăng cho thấy khả năng vượt ngưỡng trong 30 phút tới. Forecasting giúp hệ thống nhìn trước rủi ro thay vì chỉ phản ứng sau khi rủi ro đã xảy ra.

Cách làm	Ý tưởng	Điểm mạnh	Hạn chế
Threshold cứng	if value > threshold then alert	Dễ hiểu, dễ triển khai	Không dự báo tương lai; dễ báo muộn hoặc báo sai
Last Value	Dùng giá trị hiện tại làm dự báo tương lai	Baseline rất mạnh với chuỗi biến đổi chậm	Không hiểu xu hướng, lịch vận hành, biến ngoại sinh
Moving Average	Dùng trung bình cửa sổ gần nhất	Giảm nhiễu hơn Last Value	Có thể phản ứng chậm khi hệ thống thay đổi nhanh
AI model	Học ánh xạ từ feature quá khứ đến target tương lai	Có thể dùng nhiều biến và quan hệ phi tuyến	Cần dữ liệu, train/test đúng, metric và kiểm soát overfit

Câu chốt

Trước khi dùng model AI, luôn phải biết baseline đơn giản đạt được bao nhiêu. Nếu model phức tạp không hơn baseline, phải giải thích thay vì cố dùng AI bằng mọi giá.

Câu hỏi tự kiểm tra

- Trong bài toán CO2, Last Value có thể là baseline mạnh khi nào?
- Trong bài toán điện năng, vì sao chỉ nhìn giá trị hiện tại có thể chưa đủ?

- Một hệ thống AIoT nên ưu tiên model phức tạp hay model đủ tốt, ổn định và dễ giải thích?

III. Hai dataset trong Lab 4 v4

Bản v4 dùng hai dataset để sinh viên không hiểu nhầm rằng một model tốt trên mọi dữ liệu. Cùng một pipeline được áp dụng cho hai target khác nhau: Appliances và CO2. Sinh viên cần so sánh hành vi model thay vì chỉ chạy code lấy kết quả.

Dataset	Target forecasting	Horizon mặc định	Góc nhìn học được
UCI Appliances Energy Prediction	Appliances	30 phút	Dữ liệu năng lượng có nhiều và peak; model AI cần feature và metric cẩn thận
UCI Occupancy Detection / CO2 Forecasting	CO2	15 phút	Dữ liệu phòng có quán tính; baseline đơn giản có thể mạnh, giúp sinh viên không thần thánh hóa AI

Lưu ý về dữ liệu

Code có cơ chế tải dữ liệu chính thức từ UCI khi có Internet. Nếu không có Internet, project dùng sample fallback cùng schema để sinh viên vẫn chạy được toàn bộ pipeline. Kết quả smoke test trong tài liệu này được tạo từ sample fallback, không phải kết quả benchmark chính thức trên UCI.

Câu hỏi quan sát dữ liệu

- Dataset nào dao động mạnh hơn khi nhìn biểu đồ target theo thời gian?
- Dataset nào có chu kỳ ngày/đêm rõ hơn?
- Dataset nào có vẻ dễ forecast hơn? Trả lời trước khi nhìn metric.

IV. Biến time-series thành bài toán học máy

Forecasting trong lab này được viết lại thành supervised learning. Ở mỗi thời điểm t , model nhận input X gồm dữ liệu hiện tại và quá khứ gần. Output y là giá trị target tại $t + \text{horizon}$.

$X(t) = [\text{target_current}, \text{target_lag_1}, \text{target_lag_2}, \text{rolling_mean}, \text{rolling_std}, \text{time_features}, \text{sensor_features}]$

$y(t) = \text{target}(t + \text{horizon})$

Ví dụ	Input X	Target y
Appliances	Appliances hiện tại, lag 10/20/30/60/120 phút, nhiệt độ, độ ẩm, giờ trong ngày	Appliances sau 30 phút
CO2	CO2 hiện tại, CO2 quá khứ gần, nhiệt độ, độ ẩm, ánh sáng, occupancy, giờ trong ngày	CO2 sau 15 phút

Cảnh báo data leakage

Không được dùng thông tin sau thời điểm t làm feature để dự báo target tại $t + \text{horizon}$. Nếu vô tình dùng dữ liệu tương lai, metric có thể đẹp giả tạo nhưng model sẽ hỏng khi triển khai thật.

Câu hỏi tự kiểm tra

- Nếu horizon = 30 phút, dòng dữ liệu tại 09:00 đang dự báo target lúc mấy giờ?
- Vì sao target_future được tạo bằng shift âm nhưng feature lag lại dùng shift dương?
- Nếu vô tình dùng rolling mean có chứa cả giá trị tương lai, điều gì xảy ra?

V. Feature engineering: điều model cần nhìn thấy

Nhóm feature	Ví dụ	Ý nghĩa cho model
Current value	Appliances_current, CO2_current	Cho biết trạng thái hiện tại của hệ thống
Lag feature	target_lag_1, target_lag_3, target_lag_12	Cho biết quá khứ gần; giúp model nhận ra tăng/giảm
Rolling feature	rolling_mean, rolling_std, rolling_min, rolling_max	Cho biết xu hướng và độ ổn định trong một cửa sổ
Delta	target_delta_1	Cho biết biến đang tăng hay giảm so với bước trước
Time feature	hour, day_of_week, sin_hour, cos_hour	Cho biết chu kỳ vận hành theo giờ/ngày
Sensor/exogenous feature	Temperature, Humidity, Light, T_out	Biến ngoại sinh giúp giải thích target

model không tự hiểu thời gian nếu ta không cung cấp thông tin thời gian dưới dạng feature. Lag và rolling feature là cách đơn giản để biến chuỗi thời gian thành bảng dữ liệu mà các model truyền thống có thể học được.

Câu hỏi tự kiểm tra

- Lag feature và rolling feature khác nhau ở điểm nào?
- Nếu chỉ dùng CO2_current mà không dùng Light hoặc Occupancy, model có mất thông tin nào không?
- Vì sao 23h và 0h gần nhau, nhưng nếu chỉ dùng số 23 và 0 thì model có thể hiểu sai?

VI. Train / Validation / Test theo thời gian

Trong time-series, dữ liệu phải được chia theo thứ tự thời gian. Train là quá khứ xa, validation là quá khứ gần hơn dùng để chọn model và tham số, test là phần tương lai cuối cùng chỉ dùng để đánh giá cuối.

Tập dữ liệu	Tỷ lệ	Vai trò	Có được dùng nhiều lần không?
Train	60%	Huấn luyện tham số model	Có
Validation	20%	Chọn model và tuning tham số	Có kiểm soát
Test	20%	Đánh giá cuối như dữ liệu tương lai chưa từng thấy	Không nên dùng để chọn tham số

Train: dữ liệu quá khứ xa

Validation: dữ liệu sau train, dùng chọn model/tuning

Test: dữ liệu tương lai cuối cùng, chỉ dùng đánh giá cuối

Câu hỏi tự kiểm tra

- Random split làm sai bài toán time-series như thế nào?
- Nếu nhóm thử 20 bộ tham số và chọn theo test MAE, nhóm đã dùng test set sai ở đâu?
- Validation set khác test set ở điểm nào?

VII. Model trong Lab 4 v4

Tầng	Model	Vai trò trong bài học	Bắt buộc?
Baseline	Last Value	Mốc so sánh tối thiểu; nếu AI không hơn baseline thì phải giải thích	Có
Baseline	Moving Average	Dự báo mượt hơn, giảm nhiễu ngắn hạn	Có

AI dễ hiểu	Linear Regression	Cho thấy model học trọng số từ feature	Có
AI dễ hiểu	Ridge Regression	Linear model có regularization để giảm quá khớp	Có
Phi tuyến	Random Forest Regressor	Học quan hệ phi tuyến, có feature importance	Có
Nâng cao	Gradient Boosting Regressor	Model mạnh hơn, học tuần tự để sửa lỗi	Có
Khám phá	LSTM	Nhận một cửa sổ chuỗi thời gian, dành cho sinh viên khá/giỏi	Mở rộng

Điểm cần nói kỹ về LSTM

LSTM không phải phép màu. Với dữ liệu ít, target nhiễu, tuning chưa đủ hoặc feature thủ công đã mạnh, LSTM có thể không hơn Random Forest hoặc thậm chí kém baseline. Đây là bài học quan trọng: model sâu hơn không đồng nghĩa với đáng triển khai hơn.

Câu hỏi tự kiểm tra

- Vì sao phải train Last Value baseline trước Random Forest?
- Random Forest học khác Linear Regression ở điểm nào?
- Nếu LSTM test MAE cao hơn Ridge, có nên kết luận LSTM vô dụng không? Cần kiểm tra thêm gì?

VIII. Đánh giá model: đọc metric như người làm hệ thống

Metric	Công thức trực giác	Cách hiểu trong AIoT
MAE	Trung bình $ \text{actual} - \text{predicted} $	Dễ giải thích nhất: sai trung bình bao nhiêu đơn vị
RMSE	Căn trung bình bình phương lỗi	Phạt lỗi lớn mạnh hơn MAE; quan trọng khi lỗi lớn gây rủi ro
MAPE	Sai số phần trăm	Dễ truyền đạt, nhưng dễ lệch nếu actual gần 0
R2	Mức giải thích biến thiên	Cao hơn thường tốt hơn, nhưng không thay thế phân tích lỗi
Bias	Trung bình $\text{predicted} - \text{actual}$	Dương: hay dự báo cao; âm: hay dự báo thấp

Cách đọc nhanh

MAE thấp chưa đủ. Nếu RMSE cao hơn MAE nhiều, có vài thời điểm sai lớn. Nếu bias lệch một phía, model có thể gây quyết định vận hành sai theo hướng cố định.

Câu hỏi tự kiểm tra

- MAE = 20 Wh nghĩa là gì?
- RMSE cao hơn MAE nhiều gợi ý điều gì?
- MAPE có thể gây hiểu nhầm khi target gần 0 như thế nào?
- Bias âm trong dự báo CO2 nguy hiểm hơn hay bias dương? Vì sao?

IX. Tinh chỉnh tham số model

Lab này không dùng tuning như một thao tác bấm nút. Sinh viên phải hiểu tham số ảnh hưởng gì đến model, rồi mới đọc tuning_log.csv.

Tham số Random Forest	Ý nghĩa dễ hiểu	Rủi ro nếu đặt không hợp lý
n_estimators	Số cây trong rừng	Quá ít cây có thể không ổn định; quá nhiều làm chậm
max_depth	Mỗi cây được phép sâu đến đâu	Quá sâu dễ overfit; quá nông dễ underfit
min_samples_leaf	Số mẫu tối thiểu ở mỗi lá	Quá nhỏ dễ học nhiễu; quá lớn có thể mất chi tiết
random_state	Giữ kết quả lặp lại được	Không cố định seed khó so sánh thí nghiệm

```
RandomForestRegressor(n_estimators=30, max_depth=5, min_samples_leaf=2)
RandomForestRegressor(n_estimators=60, max_depth=8, min_samples_leaf=2)
RandomForestRegressor(n_estimators=80, max_depth=12, min_samples_leaf=2)
RandomForestRegressor(n_estimators=80, max_depth=None, min_samples_leaf=3)
```

Câu hỏi tự kiểm tra

- Tuning phải chọn theo validation hay test?
- max_depth tăng có luôn làm test MAE giảm không?

- Nếu train error giảm nhưng validation error tăng, model đang gặp vấn đề gì?

X. Kết quả smoke test trên gói mẫu


Bảng dưới đây là kết quả kiểm thử trong sandbox trên sample fallback. Mục tiêu không phải công bố benchmark, mà là chứng minh source chạy được và tạo đủ sản phẩm cho sinh viên phân tích.

Dataset	Best model theo validation	Test MAE	Last Value MAE	Cải thiện MAE	Test R2
appliances	GradientBoosting_advanced	23.466	27.435	14.46%	0.352
co2	Ridge_alpha_1	35.076	36.130	2.92%	0.901


Dataset	Model	Test MAE	Test RMSE	Test MAPE	Epochs
appliances	LSTM_optional	32.557	47.133	36.43%	12

Cách dùng kết quả này trên lớp


Không yêu cầu sinh viên kết luận model nào tuyệt đối tốt nhất. Yêu cầu đúng hơn là: model nào tốt hơn baseline trên dataset nào, tốt hơn bao nhiêu, có đáng đổi lấy độ phức tạp không, và vì sao LSTM không mặc nhiên thắng model truyền thống.




Hình 1. So sánh test MAE giữa các model trên Appliances.




Hình 2. So sánh test MAE giữa các model trên CO2.



Hình 3. Forecast vs Actual trên Appliances.





Hình 5. Đường loss của LSTM mở rộng trên Appliances.

Câu hỏi phân tích kết quả

- Dataset nào AI cải thiện rõ hơn so với Last Value?
- Có model nào phức tạp hơn nhưng test MAE lại không tốt hơn không?
- Nếu chọn model triển khai, em chọn theo MAE thấp nhất hay còn xét độ ổn định, tốc độ và giải thích được?
- LSTM trong smoke test có phải model tốt nhất không? Nếu không, bài học rút ra là gì?

XI. Quy trình thực hành cho sinh viên

Bước	Lệnh / thao tác	Sản phẩm	Câu hỏi phải trả lời
1	python src/download_data.py	raw data hoặc sample fallback	Máy đang dùng dữ liệu official hay sample?
2	python src/prepare_datasets.py	data/processed/*.csv	Hai dataset có bao nhiêu dòng và target nào?
3	python src/train_classical_models.py	metrics_all_models.csv, tuning_log.csv, predictions	Model nào hơn baseline?
4	python src/plot_results.py	figures/*.png	Model sai mạnh ở giai đoạn nào?

5	python src/compare_two_datasets.py	two_dataset_comparison_notes.md	Một model có tốt đều trên hai dataset không?
6	python src/train_lstm.py -- datasets appliances --epochs 12	lstm_metrics.csv, appliances_lstm.pt	LSTM có hơn model truyền thống không? Vì sao?

```
python src/download_data.py
python src/prepare_datasets.py
python src/train_classical_models.py
python src/plot_results.py
python src/compare_two_datasets.py
python src/test_local_pipeline.py
```

Mở rộng LSTM

```
pip install -r requirements_lstm.txt
python src/train_lstm.py --datasets appliances --epochs 12
```

XII. Cấu trúc source code

```
lab4_aiot_model_training_v4/
├─ data/
│  └─ raw/          # dữ liệu tải từ UCI nếu có Internet
│  └─ sample/       # sample fallback để chạy offline
│  └─ processed/     # dữ liệu đã chuẩn hóa
├─ notebooks/
│  └─ 01_understand_forecasting_ai_model.ipynb
│  └─ 02_train_models_appliances.ipynb
│  └─ 03_train_models_co2.ipynb
│  └─ 04_lstm_exploration_optional.ipynb
├─ src/
│  └─ download_data.py
│  └─ prepare_datasets.py
│  └─ feature_engineering.py
│  └─ train_classical_models.py
│  └─ train_lstm.py
│  └─ plot_results.py
│  └─ compare_two_datasets.py
│  └─ test_local_pipeline.py
├─ models/
├─ outputs/
├─ figures/
├─ requirements.txt
├─ requirements_lstm.txt
├─ README.md
├─ RUN_GUIDE.md
```

Câu hỏi đọc source

- File nào tạo lag và rolling feature?
- File nào chia train/validation/test theo thời gian?
- File nào ghi tuning_log.csv?
- File nào train LSTM? LSTM dùng input dạng bảng hay dạng sequence?

XIII. Sản phẩm sinh viên phải nộp

Nhóm sản phẩm	Yêu cầu tối thiểu
Notebook	Chạy được ít nhất 02 notebook chính; có markdown trả lời câu hỏi
Metrics	Có metrics_all_models.csv, model_comparison.csv, tuning_log.csv
Prediction	Có predictions_appliances.csv và predictions_co2.csv
Biểu đồ	Có forecast_vs_actual, error_over_time, model_comparison_mae
Model card	Có model_card_appliances.md và model_card_co2.md
LSTM mở rộng	Không bắt buộc; nhóm khá/giỏi nộp thêm lstm_metrics.csv và nhận xét
Báo cáo ngắn	1-2 trang: so sánh baseline vs AI, đọc metric, nêu giới hạn và safety note

XIV. Bộ câu hỏi bắt buộc sau lab

1. Vì sao Lab 4 v4 tập trung vào model thay vì API?
2. Model AI trong bài này học ánh xạ từ gì sang gì?
3. Lag feature khác rolling feature như thế nào?
4. Vì sao không random split time-series?
5. Validation set dùng để làm gì? Test set dùng để làm gì?
6. MAE, RMSE, MAPE, R2 và bias mỗi chỉ số nói điều gì?
7. Nếu RMSE cao hơn MAE nhiều, em cần xem biểu đồ nào?

8. Random Forest có tham số nào cần tuning? Mỗi tham số ảnh hưởng gì?
9. Dataset nào Last Value baseline mạnh? Vì sao?
10. Dataset nào AI model cải thiện nhiều hơn? Vì sao?
11. Nếu model nâng cao không hơn baseline, nhóm có nên dùng model đó trong triển khai không?
12. LSTM nhận input khác Random Forest như thế nào?
13. Vì sao LSTM không luôn tốt hơn model truyền thống?
14. Feature importance có giúp hiểu model không? Có phải bằng chứng tuyệt đối không?
15. Forecast output có nên điều khiển thiết bị trực tiếp không? Cần safety rule nào?

XV. Rubric chấm điểm Lab 4 v4

Tiêu chí	Mô tả	Điểm
Hiểu bài toán AI forecasting	Giải thích được input, target, horizon và vì sao cần model	1.0
Xử lý 2 dataset	Load, kiểm tra, chọn target đúng cho Appliances và CO2	1.0
Feature engineering	Có lag, rolling, delta, time feature và giải thích vai trò	1.5
Train/validation/test theo thời gian	Chia đúng, không random split, không leakage	1.0
Baseline	Có Last Value và Moving Average để so sánh	1.0
ML model	Train Linear/Ridge, Random Forest, Gradient Boosting	1.5
Đánh giá metric	Có MAE, RMSE, MAPE, R2, bias và biết diễn giải	1.5
Tuning tham số	Có tuning_log.csv và nhận xét trước/sau tuning	1.0
So sánh hai dataset	Rút ra nhận xét về hành vi model trên dữ liệu khác nhau	1.0
LSTM / mở rộng / safety	Có LSTM hoặc phân tích vì sao không dùng; nêu giới hạn và safety note	0.5
Tổng		10.0

XVI. Tài liệu tham khảo và nguồn dữ liệu

- UCI Machine Learning Repository - Appliances Energy Prediction:
<https://archive.ics.uci.edu/dataset/374/appliances+energy+prediction>
- UCI Machine Learning Repository - Occupancy Detection:
<https://archive.ics.uci.edu/dataset/357/occupancy+detection>
- scikit-learn documentation: <https://scikit-learn.org/stable/>
- PyTorch documentation: <https://pytorch.org/docs/stable/index.html>